DLA HW1: ASR

Кутузов Артем
Группа 231, ФКН, ВШЭ, Москва
Last Edit Date: 22 октября 2026 г.

Модель

Финальная модель - это conformer encoder + lstm predictor + joint network в качестве головы для rnnt-t. Для финальных предсказаний используется shallow fusion с предобученной LSTM-моделью flair news-forward-fast.

Обучалась при помощи конфига conformer_rnnt_train360_a6000.yaml в течение 22 часа на NVIDIA RTX A6000. Использовался датасет train-clean-360. Всего примерно 145000 батчей размером 12 каждый.

Логи и Отчет обучения.

Графики лосса, норм градиентов, метрик стабильно и ровно убывают. Это говорит о стабильном обучении. В конце выходят практически на плато на val-other, вряд ли можно ещё улучшить обучаясь только на чистых данных.

В этих логах также можно увидеть:

- learning rate
- gradient norm loss
- Метрики CER и WER на сплитах train-clean, val-clean, val-other с методами декодирования greedy (argmax) и beam-search.
- Этот эксперимент и финальные результаты показывают, что beam search дает лучшее качество, чем argmax
- Логи спектрограмм
- Логи аудио до и после аугментаций
- Сэмплы текстовых предсказаний (Из-за незначительного бага у некоторых из них вместо названия файла отображается случайный символ, но остальное верно)

Также реализованы 4 аугментации:

- Gain - изменение громкости аудио
- SpeedPerturbation - изменение скорости ауди
- AddReverb - добавление реверберации
- AddColoredNoise - добавление шума

На примеры их работы можно посмотреть в логах

Эксперименты

Я пробовал архитектуры deepspeech2 и conformer с головами ctc и rnn-t и методы декодирования argmax, beam search, shallow fushion.

Логи экспериментов старые и малоинформативные, к сожалению. Но в сданном мною репозитории поддерживается возможность обучения и инференса всех возможных комбинаций энкодера, головы и декодера, описанных выше. У меня просто не хватило времени и ресурсов на полноценные эксперименты с ними.

Deepspeech2 показал низкое качестве при требовательном обучении, поэтому я выбрал conformer как финальную архитектуру. Выбрал rnn-t так как она позволяет делать более точное выравнивание и за неё дают +1 балл.

Бонус LM

Самая сложная в реализации часть - написать собственный beam search и shallow fusion.

Потратил много времени на то, чтобы понять, как именно добавить языковую модель в beam search. Потом был долгий поиск модели, которая имеет посимвольную токенизацию, позволяет сохранять и обновлять свое промежуточное состояние и при этом работает за приемлемое время.

Такая модель была найдена - flair news-forward-fast. Потом долго оптимизировалась, чтобы ускорить инференс. Пришлось использовать кэширование и упаковку по батчам во время shallow fushion.

Результаты на тесте

Тестовая выборка никак не показывалась модели и гиперпараметры по ней не перебирались. В самом конце работы финальная модель была запущена на тестовых выборках:

Character Error Rate

Decoding method	test_clean	test_other
Greedy	0.031656	0.122413
Beam Search	0.028941	0.110156
Shallow fushion	0.025955	0.101092

Word Error Rate

Decoding method	test_clean	test_other
Greedy	0.082129	0.252259
Beam Search	0.076328	0.231626
Shallow fushion	0.067654	0.207688

Перспективы

Для улучшения качества можно:

- Файн-тюнить модель на train-other.
- Увеличивать модель, beam_size
- Попробовать BPE токенизацию

К сожалению, на все это не хватило времени и ресурсов.